

Università degli studi di Milano - Bicocca

Department of Informatics, System and Communication (DISCo)

Master's Degree in Data Science

Streaming Data Management and Time Series Analysis Project



Davide Fabio Loreti - 865309

30 gennaio 2026

1 Esplorazione dei Dati e Preprocessing

1.1 Descrizione del Dataset

Il dataset oggetto di studio consiste in una serie temporale oraria che registra il numero di pedoni che transitano davanti a un sensore installato in una strada pubblica in Australia. I dati coprono un periodo di circa 5 anni, dal 15 aprile 2015 al 29 febbraio 2020, per un totale di 42.767 osservazioni orarie.

La struttura del dataset è composta da due variabili:

- **time**: variabile temporale con formato `yyyy-mm-dd hh:mm:ss` espressa in UTC
- **value**: variabile numerica rappresentante il conteggio di pedoni

L'obiettivo del progetto è prevedere le ultime 1.439 osservazioni mancanti, corrispondenti a 60 giorni di dati orari.

1.2 Visualizzazione della Serie Temporale




Figura 1: Serie temporale completa del conteggio pedonale e dettaglio degli ultimi 30 giorni osservati

Dal grafico emergono le seguenti osservazioni:

- La serie presenta una forte variabilità intra-giornaliera, con picchi e valli che si ripetono ciclicamente
- Si osserva una stagionalità evidente a livello giornaliero, con pattern che si ripetono ogni 24 ore
- Il dettaglio degli ultimi 30 giorni rivela chiaramente la presenza di cicli settimanali, con differenze visibili tra giorni feriali e weekend
- Non si osservano trend di lungo periodo evidenti, suggerendo una serie relativamente stazionaria attorno a un livello medio

1.3 Analisi dei Pattern Stagionali

1.3.1 Stagionalità Giornaliera




Figura 2: Conteggio medio di pedoni per ora del giorno

Dalla Figura 2 è possibile notare come il traffico pedonale mostra un andamento giornaliero ben definito. I valori massimi si registrano nel pomeriggio, con un picco intorno alle ore 16:00, quando si raggiunge una media di circa 196 pedoni all'ora; questa fase di intensa frequentazione è preceduta e seguita da un plateau che si estende approssimativamente tra le 12:00 e le 17:00, durante il quale il flusso rimane elevato, con valori compresi tra 170 e 195 pedoni orari. Al contrario, nelle ore notturne il traffico si riduce drasticamente, toccando i livelli minimi tra l'1:00 e le 3:00 del mattino, con una media di circa 10 pedoni all'ora. A partire dalle prime ore del mattino si osserva una crescita graduale del flusso: intorno alle 6:00 il traffico è ancora contenuto, con circa 60 pedoni all'ora, ma aumenta progressivamente fino a raggiungere un primo picco intorno alle 9:00, con valori prossimi ai 150 pedoni all'ora. Dopo il massimo pomeridiano, infine, il traffico inizia a diminuire in modo graduale a partire dalle 18:00, quando si registrano circa 140 pedoni all'ora, proseguendo poi verso una riduzione costante che conduce nuovamente ai bassi livelli tipici delle ore notturne.

1.3.2 Stagionalità Settimanale




Figura 3: Conteggio medio di pedoni per giorno della settimana

L'analisi settimanale rivela un pattern distintivo tra giorni lavorativi e fine settimana. I primi tre giorni della settimana (lunedì, martedì e mercoledì) mostrano i valori più elevati, seguiti da un lieve calo il giovedì. Il venerdì segna una diminuzione più marcata, mentre il sabato registra il minimo settimanale. La domenica presenta una ripresa moderata, confermando una dinamica legata alle attività lavorative e scolastiche nei giorni feriali e a comportamenti ricreativi diversificati durante il weekend.

1.3.3 Stagionalità Annuale




Figura 4: Conteggio medio di pedoni per mese dell'anno

La stagionalità annuale rivela variazioni nel comportamento pedonale su scala mensile. Si osservano mesi caratterizzati da maggiore affluenza, tipicamente associati a periodi turistici o condizioni climatiche favorevoli, e mesi con un calo significativo nei flussi pedonali, spesso in coincidenza con stagioni calde o periodi festivi. Va tenuto presente, infatti, che in Australia e più in generale nell'emisfero australe, i mesi estivi sono gli ultimi e i primi dell'anno e sono

caratterizzati da elevate temperature. Il calo dei pedoni può trovare una spiegazione nel fatto che le categorie fragili, cui anziani e bambini, escano meno frequentemente soprattutto nelle ore centrali.

1.4 Analisi di Autocorrelazione




Figura 5: Funzioni di autocorrelazione (ACF) e autocorrelazione parziale (PACF) fino a 168 lag (1 settimana)

1.5 Stazionarietà

Per verificare la stazionarietà della serie temporale analizzata, sono stati condotti due tipi di test statistici: uno per la stazionarietà in media e uno per la stazionarietà in varianza.

Stazionarietà in media Per testare la stazionarietà in media è stato applicato l'*Augmented Dickey-Fuller (ADF) test*. L'output ottenuto è il seguente:

```
Augmented Dickey-Fuller Test
data: ts_data
Dickey-Fuller = -18.53, Lag order = 34, p-value = 0.01
alternative hypothesis: stationary
```

Il valore del test Dickey-Fuller è significativamente negativo e il p-value (0.01) è inferiore al livello di significatività del 5%, suggerendo quindi il rifiuto dell'ipotesi nulla di non stazionarietà e confermando che la serie è stazionaria in media.

Stazionarietà in varianza Per verificare la stazionarietà in varianza è stato condotto il *test ARCH* (LM-test). L'output riportato è il seguente:

```
ARCH LM-test; Null hypothesis: no ARCH effects
data: ts_data
Chi-squared = 30093, df = 12, p-value < 2.2e-16
```

Il risultato indica un p-value molto basso ($< 2.2e-16$), suggerendo che la varianza della serie storica non è costante nel tempo, indicando la necessità di modellare la volatilità in maniera appropriata.

2 Modellazione ARIMA

A seguito dell'analisi esplorativa e della valutazione di stazionarietà, è stata intrapresa la modellazione tramite approccio ARIMA (AutoRegressive Integrated Moving Average), con l'obiettivo di catturare sia la componente autoregressiva sia la struttura degli errori serialmente correlati presenti nella serie.

La selezione del modello è stata effettuata in ambiente R utilizzando la funzione `auto.arima()` del pacchetto `forecast`, che permette la ricerca automatica della combinazione ottimale dei parametri (p, d, q) e dei parametri stagionali $(P, D, Q)_m$ in funzione delle caratteristiche sia stagionali che non stagionali della serie.

Il modello finale selezionato è un **ARIMA(2,1,2)** con regressori esterni costituiti dalle componenti di Fourier giornaliere, settimanali e annuali, oltre a dummy per festività e weekend. La matrice dei regressori ha dimensione 41328×41 , comprensiva di tutte le componenti stagionali e indicatori di giorni speciali.

2.1 Parametri del Modello e Metriche di Adattamento

I principali parametri stimati includono:

- AR1 = 0.5281, AR2 = -0.9616
- MA1 = -0.5922, MA2 = 0.9205
- Coefficienti di Fourier giornaliere, settimanali e annuali con valori compresi tra -79.70 e 32.81
- Dummy festività e weekend tra -2.20 e 1.13

Le metriche di bontà di adattamento sul training set sono:

- $MAE = 25.84$
- $RMSE = 38.07$
- $AIC = 418198.1$, $BIC = 418595.1$

2.2 Previsioni e Analisi

Le previsioni generate dal modello ARIMA esteso sono state confrontate con gli ultimi 30 giorni osservati, mostrando una buona capacità di catturare la stagionalità giornaliera e settimanale. La distribuzione dei valori previsti varia da 0 a circa 210 pedoni/ora, con mediana intorno a 68 e media circa 76. Questi valori, reattivamente contunti rispetto ai picchi, suggerisce un buon forecast sul breve periodo ma scarso sul lungo.

Le festività e i weekend sono stati analizzati separatamente, risultando coerenti con i pattern storici osservati.




Figura 6: Confronto tra osservazioni storiche (nero) e previsioni ARIMA (blu). La linea tratteggiata rossa indica l'inizio del periodo predittivo.

3 Modellazione UCM (Unobserved Components Model)

Per confrontare i risultati ottenuti tramite ARIMA, è stato implementato un modello UCM con i seguenti componenti:

- **Local level trend:** stazionario ($Q = 0$)
- **Stagionalità oraria:** 24 ore (dummy)
- **Regressori di Fourier:** giornalieri ($K=12$), settimanali ($K=6$) e annuali ($K=1$)
- **Dummy per festività e weekend**
- **Trasformazione dei dati:** $\text{Log}(y+1)$, per stabilizzare la varianza rendere additivi eventuali valori moltiplicativi e prevenire valori negativi in fase di forecasting.

Il modello è stato stimato tramite il filtro e lo smoothing di Kalman. La previsione è stata generata per le ultime 1.439 ore (circa 60 giorni).

3.1 Statistiche di Forecast

- **Periodo di training:** 15 aprile 2015 - 31 dicembre 2019
- **Periodo di forecast:** 1 gennaio 2020 - 29 febbraio 2020
- **Numero di regressori:** 42 (Fourier giornalieri, settimanali, annuali + dummy festività)
- **Metriche in-sample** (scala originale):
 - $\text{MAE} = 35.37$
 - $\text{RMSE} = 59.26$

3.2 Forecast UCM




Figura 7: Previsioni generate dal modello UCM per il conteggio pedonale.

4 Modellazione con Algoritmi di Machine Learning

Oltre ai modelli statistici ARIMA e UCM, è stata condotta un'estesa sperimentazione con algoritmi di Machine Learning per valutare la capacità predittiva sulla serie temporale pedonale. Gli algoritmi confrontati includono: LSTM, KNN, Random Forest e XGBoost.

I risultati principali sono riportati di seguito.

4.1 Metriche dei Modelli

- **LSTM:** MAE = 14.702
- **KNN:** MAE = 18.489
- **Random Forest:** MAE = 13.548
- **XGBoost:** MAE = 13.323

Sebbene Random Forest e XGBoost abbiano il MAE più basso, la sola metrica non cattura la fedeltà alla dinamica reale della serie, poiché i modelli mostrano previsioni compresse con variabilità molto inferiore rispetto ai dati osservati.

4.2 Analisi delle Statistiche di Forecast

- **LSTM:** Mean = 176.71, Std = 150.59, Min = 0.00, Max = 555.74
- **KNN:** Mean = 50.80, Std = 50.68, Min = 0.00, Max = 303.40
- **Random Forest:** Mean = 15.79, Std = 10.62, Min = 0.98, Max = 40.96
- **XGBoost:** Mean = 13.45, Std = 10.91, Min = 1.41, Max = 42.56
- **Dati reali:** Mean = 101.51, Std = 103.17, Min = 0.00, Max = 906.00




Figura 8: Ultime 200 osservazione previste dai modelli e osservate

RF e XGBoost risultano eccessivamente smorzati: generano forecast troppo piatti, con un range molto inferiore alla variabilità reale. Il KNN ha una variabilità maggiore ma ancora insufficiente.

LSTM, al contrario, mantiene una distribuzione più coerente con la dinamica reale, catturando picchi, stagionalità e ampiezza delle oscillazioni.

Il modello selezionato per il forecasting finale è l'LSTM. Questa scelta è motivata non solo dalla buona accuratezza ottenuta, con un errore medio assoluto pari a 14.702, ma soprattutto dalla capacità del modello di adattarsi in modo efficace alla forma globale della serie temporale. In particolare, l'LSTM è in grado di mantenere una variabilità predittiva compatibile con quella osservata nei dati reali, evitando eccessive semplificazioni.

Inoltre, riesce a riprodurre una struttura stagionale più credibile rispetto ad altri modelli di machine learning, catturando in modo coerente sia i picchi di traffico sia i pattern ricorrenti su base giornaliera e settimanale.

Un ulteriore punto di forza è il comportamento dinamico delle previsioni, che non risultano appiattite nel tempo, come spesso accade nei modelli tree-based, ma conservano una risposta più flessibile e aderente alle dinamiche temporali della serie.




Figura 9: Adattamento dei modelli nelle ultime 200 osservazioni.